文本分类实验报告

词袋模型 平均词向量 BERT 微调

本实验在统一 NYT 新闻划分上比较六种文本分类方法。Binary BoW 的测试 Accuracy 为 0.9896、Macro-F1 为 0.9779，在本次实验中排名第一。BERT 完整训练三轮并按验证集选择检查点，其测试 Macro-F1 为 0.9542。结果表明，完整新闻中的关键词信息对本任务有效，模型复杂度增加没有自动带来更高测试分数。

一 作业目标与实现范围

任务	表示方式	分类器	统一要求
Task 1	Binary BoW 与 Word Frequency	Logistic Regression	两组词袋实验
Task 2	GloVe AG Word2Vec NYT Word2Vec	Logistic Regression	100 维 平均词向量
Task 3	google-bert/bert-base-uncased	BERT 分类头	长度 64 训练 3 轮

Task 1 按更正后的要求实现两种表示，不额外增加第三种词袋方法。全部六组实验报告 Accuracy 和 Macro-F1，最终评价使用相同的 NYT Test Set。AG News 的文本仅用于 Word2Vec 训练，不参与 NYT 分类标签学习。

二 数据来源与类别分布

实验使用提供的 nyt.csv 和 ag.csv，分别包含 11,519 条带标签新闻和 90,000 条无标签文本。两份文件均不存在缺失文本或空文本；NYT 标签为 business、politics 和 sports。

类别	全体	占比	训练	验证	测试
business	1429	12.41%	1137	155	137
politics	1451	12.60%	1127	172	152
sports	8639	75.00%	6951	825	863
合计	11519	100%	9215	1152	1152

三 统一划分和数据边界

设置随机种子 42，通过 NumPy 随机置换全部 NYT 行，前 80% 为训练集，随后 10% 为验证集，剩余 10% 为测试集。整数截断后样本数分别为 9,215、1,152、1,152。未额外分层，全部方法读取同一份 split.json 行号。

训练集用于构建词表、训练 NYT Word2Vec、拟合标准化参数以及训练分类器；验证集仅选择 LR 的 C 和 BERT 检查点；测试集仅作最终评价。split.json 保存标签映射及原始 NYT 文件 SHA256，核验脚本检查行号无交集且覆盖全部样本。

四 文本表示与分类方法

4.1 统一预处理与两种词袋表示

前五组方法先将文本转为小写，再用正则表达式提取英文单词、词内撇号和数字。不删除停用词，不使用 TF-IDF，不限制最大词表。词表完全由 NYT 训练集建立，验证集和测试集中的未登录词不增加词表维度。

两种词袋共有 65,818 个训练词。设词 i 在文档 d 中出现 c_i(d) 次，则 Binary BoW 定义为 x_i(d)=1 当 c_i(d)>0，否则为 0；Word Frequency 定义为 x_i(d)=c_i(d)。

示例文本	词表顺序	Binary BoW	Word Frequency
apple apple banana	apple banana	[1, 1]	[2, 1]

Binary BoW 保留出现与否，减少重复词频对权重的放大；Word Frequency 保留重复强度，但也更受文档长度影响。特征使用稀疏矩阵存储，避免为每篇新闻创建大规模稠密向量。

4.2 三种 100 维词向量

方法	词向量来源	NYT 标签的作用
GloVe	glove.6B.100d 公开预训练文件	仅训练 LR 分类器
Word2Vec AG	ag.csv 全部 90,000 条文本	仅训练 LR 分类器
Word2Vec NYT	NYT 训练集 9,215 条文本	仅训练 LR 分类器

GloVe 词向量固定，不在 NYT 上更新；文件经 SHA256 验证。两种 Word2Vec 使用相同参数：Skip-gram、vector_size=100、window=5、min_count=2、negative=5、epochs=5、workers=1、seed=42。单线程与固定词哈希函数减少训练随机差异。

对于 n 个已登录词，文档向量为 e(d)=(e(w1)+...+e(wn))/n。重复出现的词按出现次数参与平均，未登录词不计入分母；全为未登录词时使用 100 维零向量。平均表示固定维度，但丢失词序和局部组合信息。

4.3 Logistic Regression 与参数选择

前五组实验均采用多类 Logistic Regression，solver=lbfgs、max_iter=2000。C 是正则化强度的倒数，候选值为 0.1、1、10。每个候选模型只在训练集拟合，选择验证 Macro-F1 最大的 C；出现同分时保留先遍历的较小 C。

三种平均词向量先使用 StandardScaler 标准化，均值和标准差只在训练集拟合。词袋不标准化。选择 C 后不合并验证集重训，因此所有最终分类器均遵循相同训练边界。

4.4 评价指标

Accuracy=正确预测数/测试样本数。对类别 k，Precision_k=TP_k/(TP_k+FP_k)，Recall_k=TP_k/(TP_k+FN_k)，F1_k=2×Precision_k×Recall_k/(Precision_k+Recall_k)。
Macro-F1=(F1_business+F1_politics+F1_sports)/3。

sports 在测试集中占 74.91%。始终预测 sports 的 Accuracy 为 0.7491，Macro-F1 却只有 0.2855。因此必须同时关注少数类别的分类质量；实现将全部三类纳入宏平均，零分母按 0 处理。

五 词袋与词向量实验结果

5.1 NYT 测试集结果

方法	Accuracy	Macro-F1	误分类篇数
Binary BoW	0.9896	0.9779	12
Word Frequency	0.9896	0.9752	12
GloVe	0.9870	0.9691	15
Word2Vec AG	0.9809	0.9547	22
Word2Vec NYT	0.9852	0.9624	17

Binary BoW 与 Word Frequency 均错分 12 篇，Accuracy 相同，但 Macro-F1 分别为 0.9779 和 0.9752。相同总错误数可以分布在不同类别，Macro-F1 可以揭示 Accuracy 掩盖的差异。

5.2 验证集选择记录

方法	C 0.1 验证 F1	C 1 验证 F1	C 10 验证 F1	选中 C
Binary BoW	0.9684	0.9664	0.9526	0.1
Word Frequency	0.9613	0.9649	0.9678	10.0
GloVe	0.9594	0.9583	0.9558	0.1
Word2Vec AG	0.9435	0.9460	0.9437	1.0
Word2Vec NYT	0.9659	0.9643	0.9662	10.0

Binary BoW 选择较强正则化 C=0.1，而 Word Frequency 选择 C=10。两种特征的数值尺度和词频分布不同，因此相同的 C 不必适合两种表示。该选择完全依据验证结果，而非测试结果。

5.3 已登录词覆盖率

词向量方法	训练覆盖率	验证覆盖率	测试覆盖率	测试零向量文档
GloVe	98.17%	98.20%	98.18%	0
Word2Vec AG	97.11%	97.11%	97.04%	0
Word2Vec NYT	99.68%	99.22%	99.19%	0

覆盖率按词出现次数计算：有对应向量的 token 数除以全部 token 数。三种表示在测试集均无全未登录词文档，因而零向量回退没有直接影响本次测试结果。覆盖率较高不等于更高分类分数，因为向量质量及均值压缩同样影响表示。

NYT Word2Vec 相比 AG Word2Vec 的 Macro-F1 高 0.0077。领域匹配可能带来帮助，但两种语料的文档长度、词频和规模同时不同，不能单独把差值归因于领域。GloVe 的 Macro-F1 为 0.9691，高于两种自行训练的词向量。

两种词袋在本次任务上优于平均词向量。稀疏词袋能够直接保留新闻类别相关的词汇线索；100 维均值向量把大量词的信息压缩成同一表示，可能削弱细粒度关键词区分能力。该解释符合表示机制，但本实验未用消融验证其因果作用。

六 BERT 微调与序列截断分析

6.1 模型与训练实现

参数	设置
预训练模型	google-bert/bert-base-uncased
最大长度	64 含 CLS 与 SEP 文本最多 62 个内容 token
训练轮数与 batch	完整 3 epochs batch_size=16
优化器	AdamW lr=2e-5 weight_decay=0.01
梯度与设备	梯度范数裁剪 1 CPU 16 线程 bfloat16 混合精度
选择依据	每轮验证 Macro-F1 最优检查点

使用 BERT 自带的 uncased WordPiece 分词器，截断长新闻并填充至 64，提供 attention_mask。分类头从随机初始化开始，BERT 编码器和分类头的全部参数共同微调。模型切换到 eval 后进行验证，评价时关闭梯度和训练 dropout。

6.2 三轮训练与验证记录

Epoch	训练 loss	验证 Accuracy	验证 Macro-F1
1	0.1486	0.9644	0.9272
2	0.0519	0.9757	0.9540
3	0.0230	0.9688	0.9410

训练 loss 从第一轮的 0.1486 变为第三轮的 0.0230。验证 Macro-F1 最高值为 0.9540，来自第 2 轮。因此完整完成三轮训练后，使用第 2 轮检查点，测试 Accuracy=0.9783，Macro-F1=0.9542。最后一轮验证分数低于最佳轮次，这与过拟合可能性一致，但不能仅凭三轮记录证明唯一原因。

6.3 实测文本长度与截断比例

NYT 正则分词后的文档长度中位数为 690 个词。BERT WordPiece 长度含特殊 token，中位数为 873、均值为 835.0、95 分位数为 1329，远大于作业规定的 64。

集合	文档数	超过 64 的文档数	被截断比例
训练	9215	9212	99.97%
验证	1152	1151	99.91%
测试	1152	1151	99.91%

测试集 1,151 篇被截断，只有 1 篇无需截断。词袋与平均词向量使用全文，而 BERT 仅使用新闻开头，因此实验中的文本可见范围不同。BERT 较低分数与信息截断相容，但本实验遵守长度 64 的要求，没有额外训练长序列模型，不能据此给出截断的因果效应。

七 六组方法的总体比较

方法	Accuracy	Macro-F1	相对 Binary BoW 的 F1 差
Binary BoW	0.9896	0.9779	+0.0000
Word Frequency	0.9896	0.9752	−0.0026
GloVe	0.9870	0.9691	−0.0087
Word2Vec AG	0.9809	0.9547	−0.0231
Word2Vec NYT	0.9852	0.9624	−0.0154
BERT	0.9783	0.9542	−0.0236

7.1 每个类别的 F1

方法	business	politics	sports
Binary BoW	0.9627	0.9744	0.9965
Word Frequency	0.9630	0.9644	0.9983
GloVe	0.9520	0.9577	0.9977
Word2Vec AG	0.9265	0.9412	0.9965
Word2Vec NYT	0.9407	0.9477	0.9988
BERT	0.9294	0.9408	0.9925

所有模型的 sports F1 都较高，主要差异出现在 business 与 politics。Binary BoW 的 politics 召回率为 1.0000，152 篇真实 politics 新闻全部识别正确，但有 8 篇其他新闻被预测为 politics，因此其精确率为 0.9500。高召回不能替代精确率分析。

7.2 BERT 与 Binary BoW 的逐样本比较

同一测试文档的预测关系	数量
两者均正确	1119
只有 Binary BoW 正确	21
只有 BERT 正确	8
两者均错误	4

BERT 独自识别正确 8 篇，Binary BoW 独自识别正确 21 篇。Binary BoW 总计错 12 篇，BERT 错 25 篇，净差为 13 篇；两者的互补关系可以从表中直接观察。

两个模型的 sports 行完全相同：859 篇预测正确、2 篇判为 business、2 篇判为 politics。新增错误来自 business 多错 4 篇及 politics 多错 9 篇。宏平均对三类赋相同权重，因而这些少数类差异会明显影响 Macro-F1。

八 混淆矩阵与错误分布

以下均为测试集原始计数。每张矩阵的行是真实类别、列是预测类别，顺序为 business、politics、sports。对角线代表正确预测；各行总数分别为 137、152、863。

Binary BoW

真实 / 预测	business	politics	sports
business	129	6	2
politics	0	152	0
sports	2	2	859

Word Frequency

真实 / 预测	business	politics	sports
business	130	6	1
politics	3	149	0
sports	0	2	861

GloVe

真实 / 预测	business	politics	sports
business	129	7	1
politics	4	147	1
sports	1	1	861

Word2Vec AG

真实 / 预测	business	politics	sports
business	126	9	2
politics	7	144	1
sports	2	1	860

Word2Vec NYT

真实 / 预测	business	politics	sports
business	127	9	1
politics	6	145	1
sports	0	0	863

BERT

真实 / 预测	business	politics	sports
business	125	7	5
politics	5	143	4
sports	2	2	859

Binary BoW 最常见的混淆方向是 business→politics，共 6 篇。BERT 的 business→politics 为 7 篇、politics→business 为 5 篇，说明商业政策与政治议题之间存在语义交叉。

误分类不是只由少数类样本少造成的：sports 新闻也可能以经济或法律事件开头。下一节展示真实案例，帮助区分关键词混淆、类别边界交叉和短序列可见范围的问题。

矩阵能定位错误方向，但不能证明单个词直接导致了预测；本实验未执行注意力解释、特征贡献分解或因果消融。

九 误分类案例分析

案例从预测导出文件与原始 CSV 对齐取得，行号为 nyt.csv 的零基数据行号。先选取每种错误方向在测试顺序中的首个案例，再展示其中六例；摘录只清理不可见控制字符用于排版，训练输入保持原样。

案例 5363 Binary BoW business → politics

原文开头 if steve boedefeld graduates from appalachian state university without any student loan debt, it will be because of the money he earned fighting in iraq and ...

新闻讨论学生债务和学费，但开头同时出现伊拉克、阿富汗及参战经历。金融主题和政治词汇交叉，Binary BoW 将 business 判为 politics。

案例 2371 Binary BoW sports → business

原文开头 recife, brazil — for soccer fans flocking to confederations cup matches in brazil's tropical northeast next week, getting tickets to the stadium should be ...

新闻涉及足球赛事观众的住宿安排，包含旅游、酒店和城市服务内容。全文词袋仍误判为 business，说明保留全文不能消除跨主题混淆。

案例 750 BERT business → sports

原文开头 london — three of the biggest british department store chains were accused friday of colluding on prices with a maker of sports bras.the office of fair ...

新闻主题是商店与内衣制造商涉嫌价格串谋；sports bras 是商品名称。BERT 将 business 判为 sports，运动相关词汇与体育新闻主题发生交叉。

案例 5018 BERT politics → sports

原文开头 helena, mont. — a former quarterback for the university of montana was acquitted friday of rape in a trial that riveted the city of missoula.the quarterback, ...

新闻围绕运动员的刑事审判，数据标签为 politics。BERT 预测 sports，反映球员身份与法律事件所属类别之间的主题边界交叉。

案例 8198 BERT sports → politics

原文开头 birmingham, ala. — a woman charged with killing another woman at a party was angry that the victim and others did not seem upset over alabama's loss to its ...

新闻开头是一起凶杀案件，背景为橄榄球赛后的球迷冲突，数据标签为 sports。BERT 预测 politics；开头本身就同时包含犯罪与体育内容，不能仅归因于后文截断。

案例 10166 BERT politics → business

原文开头 some texas animal shelters have until january to comply with a new law that bans the use of compressed carbon monoxide to euthanize dogs and cats. although the ...

新闻讨论动物收容所执行新法规，同时强调改造成本。数据标签为 politics，BERT 预测 business，表明法规与经营成本信息可以激活不同类别线索。

这些案例是预测结果的事后定性分析，不代表全部错分文档，也不等价于模型因果解释。完整十例和六组逐样本预测保存在 analysis.json 与各组 predictions.csv。

十 复现说明与结论

10.1 代码入口与实际运行

克隆仓库后进入项目目录，使用 Python 3.12 创建虚拟环境并安装 requirements.txt。数据 nyt.csv 和 ag.csv 放在根目录。下列命令分开运行六组实验；完整运行说明见 运行说明.md。

```
python -m venv .venv
.venv/Scripts/python.exe -m pip install -r requirements.txt
.venv/Scripts/python.exe download_glove.py
.venv/Scripts/python.exe experiment.py --task bow
.venv/Scripts/python.exe experiment.py --task embeddings --glove assets/glove.6B.100d.txt
.venv/Scripts/python.exe experiment.py --task bert --threads 16 --bf16
.venv/Scripts/python.exe analyze_results.py
.venv/Scripts/python.exe validate_results.py
.venv/Scripts/python.exe report.py
```

Linux 或 macOS 将 Python 路径改为 .venv/bin/python。bfloat16 需设备支持，不支持时去掉 --bf16；本次实测使用 CPU 16 线程和 bfloat16。报告嵌入中文 TrueType 字体；非 Windows 环境通过 REPORT_FONT 指定字体路径。

10.2 实际依赖版本与保存证据

依赖	实测版本	依赖	实测版本
numpy	2.2.6	pandas	2.2.3
scikit-learn	1.6.1	scipy	1.18.1
gensim	4.4.0	torch	2.7.1
transformers	4.51.3	reportlab	5.0.1

experiment.py 实现全部六组训练；test_core.py 检查词频、均值向量和划分语义；validate_results.py 重新计算 Accuracy、Macro-F1 和混淆矩阵，并核验原始数据 SHA256。results 保存划分、验证记录、分类报告和逐样本预测；assets 和大模型检查点不纳入 Git 仓库。

10.3 结论与局限

在该数据与统一划分下，Binary BoW 的 Macro-F1 最高。Word Frequency 保留频次，但未超过二值词袋；平均词向量保留语义相似性但压缩了全文关键词；BERT 能建模上下文，但受到长度 64 和训练轮数 3 的规定约束。

原始 NYT 有 72 条重复文本，训练与验证、训练与测试、验证与测试分别重叠 12、15、1 个不同文本。为遵循随机划分要求保留原始数据，这可能使评价偏乐观。本实验只运行一个随机种子，未进行多次运行、统计显著性检验或长序列消融；对模型机制的解释应视为有证据支持的可能原因。

参考资料

Pennington 等 GloVe 2014。https://nlp.stanford.edu/projects/glove/

Devlin 等 BERT 2019。https://aclanthology.org/N19-1423/

模型来源 https://huggingface.co/google-bert/bert-base-uncased